

## ☰ Contents

특잇값과 특이벡터
특잇값 분해 행렬의 크기
예제
특잇값 분해의 축소형
예제
파이썬을 사용한 특이분해
연습 문제 3.4.1
특잇값과 특이벡터의 관계
예제
연습 문제 3.4.2
특이분해와 고유분해의 관계
연습 문제 3.4.3
1차원 근사
1차원 근사의 풀이
일반적인 풀이
랭크-1 근사문제
K 차원 근사
랭크-K 근사문제

## 3.4 특잇값 분해

정방행렬은 고유분해로 고윳값과 고유벡터를 찾을 수 있었다. 정방행렬이 아닌 행렬은 고유분해가 불가능하다. 하지만 대신 고유분해와 비슷한 특이분해를 할 수 있다.

## 특잇값과 특이벡터

$N \times M$  크기의 행렬  $A$ 를 다음과 같은 3개의 행렬의 곱으로 나타내는 것을 **특이분해(singular-decomposition)** 또는 **\*\*특잇값 분해(singular value decomposition)\*\***라고 한다.

$$A = U\Sigma V^T$$

여기에서  $U, \Sigma, V$ 는 다음 조건을 만족해야 한다.

- 대각성분이 양수인 대각행렬이어야 한다. 큰 수부터 작은 수 순서로 배열한다.

$$\Sigma \in \mathbf{R}^{N \times M}$$

- $U$ 는  $N$ 차원 정방행렬로 모든 열벡터가 단위벡터이고 서로 직교해야 한다.

$$U \in \mathbf{R}^{N \times N}$$

- $V$ 는  $M$ 차원 정방행렬로 모든 열벡터가 단위벡터이고 서로 직교해야 한다.

$$V \in \mathbf{R}^{M \times M}$$

위 조건을 만족하는 행렬  $\Sigma$ 의 대각성분들을 **특잇값(singular value)**, 행렬  $U$ 의 열벡터들을 **왼쪽 특이벡터(left singular vector)**, 행렬  $V$ 의 열벡터들을 **오른쪽 특이벡터(right singular vector)**라고 부른다.

[정리] 특이분해는 모든 행렬에 대해 가능하다. 즉 어떤 행렬이 주어지더라도 위와 같이 특이분해할 수 있다.

증명은 이 책의 범위를 벗어나므로 생략한다.

## 특잇값 분해 행렬의 크기

특잇값의 개수는 행렬의 열과 행의 개수 중 작은 값과 같다. 특이분해된 형태를 구체적으로 쓰면 다음과 같다.

만약  $N > M$ 이면  $\Sigma$  행렬이  $M$ 개의 특잇값(대각성분)을 가지고 다음처럼 아랫 부분이 영행렬이 된다.

$$A = \begin{bmatrix} u_1 & u_2 & u_3 & \cdots & u_M & \cdots & u_N \end{bmatrix} \begin{bmatrix} \sigma_1 & 0 & 0 & \cdots & 0 \\ 0 & \sigma_2 & 0 & \cdots & 0 \\ 0 & 0 & \sigma_3 & \cdots & 0 \\ \vdots & \vdots & \vdots & \ddots & \vdots \\ 0 & 0 & 0 & \cdots & \sigma_M \\ 0 & 0 & 0 & \cdots & 0 \\ \vdots & \vdots & \vdots & & \vdots \\ 0 & 0 & 0 & \cdots & 0 \end{bmatrix} \begin{bmatrix} v_1^T \\ v_2^T \\ \vdots \\ v_M^T \end{bmatrix}$$

반대로  $N < M$ 이면  $\Sigma$  행렬이  $N$ 개의 특잇값(대각성분)을 가지고 다음처럼 오른쪽 부분이 영행렬이 된다.

$$A = \begin{bmatrix} u_1 & u_2 & \cdots & u_N \end{bmatrix} \begin{bmatrix} \sigma_1 & 0 & 0 & \cdots & 0 & 0 & \cdots & 0 \\ 0 & \sigma_2 & 0 & \cdots & 0 & 0 & \cdots & 0 \\ 0 & 0 & \sigma_3 & \cdots & 0 & 0 & \cdots & 0 \\ \vdots & \vdots & \vdots & \ddots & \vdots & \vdots & & \vdots \\ 0 & 0 & 0 & \cdots & \sigma_N & 0 & \cdots & 0 \end{bmatrix} \begin{bmatrix} v_1^T \\ v_2^T \\ v_3^T \\ \vdots \\ v_N^T \\ \vdots \\ v_M^T \end{bmatrix}$$

행렬의 크기만 표시하면 다음과 같다.

$$\overset{M}{\sim} \qquad \qquad \qquad \overset{N}{\sim} \\ N \Big\{ \quad A \quad = N \Big\{ \quad U \qquad \qquad \overset{M}{\sim} \quad \overset{M}{\sim} \quad V^T \quad \Big\} M$$

또는

$$\overset{M}{\sim} \qquad \qquad \qquad \overset{N}{\sim} \qquad \qquad \overset{M}{\sim} \qquad \qquad \overset{M}{\sim} \\ N \{ \quad A \quad = N \{ \quad U \qquad \qquad \Sigma \qquad \qquad V^T \quad \} M$$

## 예제

행렬  $A$

$$A = \begin{bmatrix} 3 & -1 \\ 1 & 3 \\ 1 & 1 \end{bmatrix}$$

는 다음처럼 특이분해할 수 있다.

$$A = \begin{bmatrix} -\frac{1}{\sqrt{6}} & \frac{2}{\sqrt{5}} & -\frac{1}{\sqrt{6}} \\ -\frac{2}{\sqrt{6}} & -\frac{1}{\sqrt{5}} & -\frac{2}{\sqrt{30}} \\ -\frac{1}{\sqrt{6}} & 0 & \frac{5}{\sqrt{30}} \end{bmatrix} \begin{bmatrix} \sqrt{12} & 0 \\ 0 & \sqrt{10} \\ 0 & 0 \end{bmatrix} \begin{bmatrix} -\frac{1}{\sqrt{2}} & -\frac{1}{\sqrt{2}} \\ \frac{1}{\sqrt{2}} & -\frac{1}{\sqrt{2}} \end{bmatrix}$$

## 특잇값 분해의 축소형

특잇값 대각행렬에서 0인 부분은 사실상 아무런 의미가 없기 때문에 대각행렬의 0 원소 부분과 이에 대응하는 왼쪽(혹은 오른쪽) 특이벡터들을 없애고 다음처럼 축소된 형태로 해도 마찬가지로 원래 행렬이 나온다.

$N$ 이  $M$ 보다 큰 경우에는 왼쪽 특이벡터 중에서  $u_{M+1}, \cdots, u_N$ 을 없앤다.

$$A = \begin{bmatrix} u_1 & u_2 & \cdots & u_M \end{bmatrix} \begin{bmatrix} \sigma_1 & 0 & 0 & \cdots & 0 \\ 0 & \sigma_2 & 0 & \cdots & 0 \\ 0 & 0 & \sigma_3 & \cdots & 0 \\ \vdots & \vdots & \vdots & \ddots & \\ 0 & 0 & 0 & \cdots & \sigma_M \end{bmatrix} \begin{bmatrix} v_1^T \\ v_2^T \\ \vdots \\ v_M^T \end{bmatrix}$$

$N$ 이  $M$ 보다 작은 경우에는 오른쪽 특이벡터 중에서  $v_{N+1}, \cdots, v_M$ 을 없앤다.

$$A = \begin{bmatrix} u_1 & u_2 & \cdots & u_N \end{bmatrix} \begin{bmatrix} \sigma_1 & 0 & 0 & \cdots & 0 \\ 0 & \sigma_2 & 0 & \cdots & 0 \\ 0 & 0 & \sigma_3 & \cdots & 0 \\ \vdots & \vdots & \vdots & \ddots & \vdots \\ 0 & 0 & 0 & \cdots & \sigma_N \end{bmatrix} \begin{bmatrix} v_1^T \\ v_2^T \\ \vdots \\ v_N^T \end{bmatrix}$$

축소형의 경우에도 행렬의 크기만 표시하면 다음과 같다.

$$N \times M \quad A = N \times N \times N \times M \quad \begin{bmatrix} U & \Sigma & V^T \end{bmatrix}$$

또는

$$N \times M \quad A = N \times N \times N \times M \quad \begin{bmatrix} U & \Sigma & V^T \end{bmatrix}$$

## 예제

행렬  $A$

$$A = \begin{bmatrix} 3 & -1 \\ 1 & 3 \\ 1 & 1 \end{bmatrix}$$

의 특이분해 축소형은 다음과 같다.

$$A = \begin{bmatrix} -\frac{1}{\sqrt{6}} & \frac{2}{\sqrt{5}} \\ -\frac{2}{\sqrt{6}} & -\frac{1}{\sqrt{5}} \\ -\frac{1}{\sqrt{6}} & 0 \end{bmatrix} \begin{bmatrix} \sqrt{12} & 0 \\ 0 & \sqrt{10} \end{bmatrix} \begin{bmatrix} -\frac{1}{\sqrt{2}} & -\frac{1}{\sqrt{2}} \\ \frac{1}{\sqrt{2}} & -\frac{1}{\sqrt{2}} \end{bmatrix}$$

## 파이썬을 사용한 특이분해

`numpy.linalg` 서브패키지와 `scipy.linalg` 서브패키지에서는 특이분해를 할 수 있는 `svd()` 명령을 제공한다. 오른쪽 특이행렬은 전치행렬로 출력된다는 점에 주의하라.

```
from numpy.linalg import svd
```

```
A = np.array([[3, -1], [1, 3], [1, 1]])
U, S, VT = svd(A)
```

U

```
array([[ -4.08248290e-01,  8.94427191e-01, -1.82574186e-01],
       [-8.16496581e-01, -4.47213595e-01, -3.65148372e-01],
       [-4.08248290e-01, -2.06937879e-16,  9.12870929e-01]])
```

S

```
array([3.46410162, 3.16227766])
```

```
np.diag(S, 1)[:, 1:]

array([[3.46410162, 0.          ],
       [0.          , 3.16227766],
       [0.          , 0.          ]])

VT

array([[ -0.70710678, -0.70710678],
       [ 0.70710678, -0.70710678]])

U @ np.diag(S, 1)[:, 1:] @ VT

array([[ 3., -1.],
       [ 1., 3.],
       [ 1., 1.]])
```

축소형을 구하려면 인수 full\_matrices=False로 지정한다.

```
U2, S2, VT2 = svd(A, full_matrices=False)

U2

array([[ -4.08248290e-01,  8.94427191e-01],
       [-8.16496581e-01, -4.47213595e-01],
       [-4.08248290e-01, -2.06937879e-16]])

S2

array([3.46410162, 3.16227766])

VT2

array([[ -0.70710678, -0.70710678],
       [ 0.70710678, -0.70710678]])

U2 @ np.diag(S2) @ VT2

array([[ 3., -1.],
       [ 1., 3.],
       [ 1., 1.]])
```

### 연습 문제 3.4.1

NumPy를 사용하여 다음 행렬을 특잇값 분해를 한다(축소형이 아닌 방법과 축소형 방법을 각각 사용한다). 또한 다시 곱해서 원래의 행렬이 나오는 것을 보여라.

$$B = \begin{bmatrix} 3 & 2 & 2 \\ 2 & 3 & -2 \end{bmatrix}$$

$$C = \begin{bmatrix} 2 & 4 \\ 1 & 3 \\ 0 & 0 \\ 0 & 0 \end{bmatrix}$$

## 특잇값과 특이벡터의 관계

행렬  $V$ 는 정규직교(orthonormal)행렬이므로 전치행렬이 역행렬이다.

$$V^T = V^{-1}$$

특이분해된 등식의 양변에  $V$ 를 곱하면,

$$AV = U\Sigma V^T V = U\Sigma$$

$$A\begin{bmatrix} v_1 & v_2 & \cdots & v_M \end{bmatrix} = \begin{bmatrix} u_1 & u_2 & \cdots & u_N \end{bmatrix} \begin{bmatrix} \sigma_1 & 0 & \cdots \\ 0 & \sigma_2 & \cdots \\ \vdots & \vdots & \ddots \end{bmatrix}$$

행렬  $A$ 를 곱하여 정리하면  $M$ 이  $N$ 보다 클 때는

$$\begin{bmatrix} Av_1 & Av_2 & \cdots & Av_N \end{bmatrix} = \begin{bmatrix} \sigma_1 u_1 & \sigma_2 u_2 & \cdots & \sigma_N u_N \end{bmatrix}$$

이 되고  $N$ 이  $M$ 보다 클 때는

$$\begin{bmatrix} Av_1 & Av_2 & \cdots & Av_M \end{bmatrix} = \begin{bmatrix} \sigma_1 u_1 & \sigma_2 u_2 & \cdots & \sigma_M u_M \end{bmatrix}$$

이 된다.

즉,  $i$ 번째 특잇값  $\sigma_i$ 와 특이벡터  $u_i, v_i$ 는 다음과 같은 관계가 있다.

$$Av_i = \sigma_i u_i \ (i = 1, \cdots, \min(M, N))$$

이 관계는 고유분해와 비슷하지만 고유분해와는 달리 좌변과 우변의 벡터가 다르다.

## 예제

위에서 예로 들었던 행렬의 경우,

$$\begin{bmatrix} 3 & -1 \\ 1 & 3 \\ 1 & 1 \end{bmatrix} \begin{bmatrix} -\frac{1}{\sqrt{2}} \\ -\frac{1}{\sqrt{2}} \end{bmatrix} = \sqrt{12} \begin{bmatrix} -\frac{1}{\sqrt{6}} \\ -\frac{2}{\sqrt{6}} \\ -\frac{1}{\sqrt{6}} \end{bmatrix}$$

$$\begin{bmatrix} 3 & -1 \\ 1 & 3 \\ 1 & 1 \end{bmatrix} \begin{bmatrix} \frac{1}{\sqrt{2}} \\ -\frac{1}{\sqrt{2}} \end{bmatrix} = \sqrt{10} \begin{bmatrix} \frac{2}{\sqrt{5}} \\ -\frac{1}{\sqrt{5}} \\ 0 \end{bmatrix}$$

가 성립한다.

## 연습 문제 3.4.2

NumPy를 사용하여 다음 행렬에 대해

$$Av_i = \sigma_i u_i$$

가 성립한다는 것을 계산으로 보여라.

$$B = \begin{bmatrix} 3 & 2 & 2 \\ 2 & 3 & -2 \end{bmatrix}$$

$$C = \begin{bmatrix} 2 & 4 \\ 1 & 3 \\ 0 & 0 \\ 0 & 0 \end{bmatrix}$$

# 특이분해와 고유분해의 관계

행렬  $A$ 의 분산행렬  $A^T A$ 는

$$A^T A = (V \Sigma^T U^T)(U \Sigma V^T) = V \Lambda V^T$$

가 되어 행렬  $A$ 의 특잇값의 제곱(과 0)이 분산행렬  $A^T A$ 의 고유값, **행렬  $A$ 의 오른쪽 특이벡터가 분산행렬  $A^T A$ 의 고유벡터가 된다.**

위 식에서  $\Lambda$ 은  $N$ 이  $M$ 보다 크면

$$\Lambda = \begin{bmatrix} \sigma_1^2 & 0 & \cdots & 0 \\ 0 & \sigma_2^2 & \cdots & 0 \\ \vdots & \vdots & \ddots & \vdots \\ 0 & 0 & \cdots & \sigma_M^2 \end{bmatrix}$$

이고  $N$ 이  $M$ 보다 작으면

$$\Lambda = \begin{bmatrix} \sigma_1^2 & 0 & \cdots & 0 & \cdots & 0 \\ 0 & \sigma_2^2 & \cdots & 0 & \cdots & 0 \\ \vdots & \vdots & \ddots & \vdots & \vdots & \vdots \\ 0 & 0 & \cdots & \sigma_N^2 & \cdots & 0 \\ \vdots & \vdots & \cdots & \vdots & \ddots & \vdots \\ 0 & 0 & \cdots & 0 & \cdots & 0 \end{bmatrix} = \text{diag}(\sigma_1^2, \sigma_2^2, \cdots, \sigma_N^2, 0, \cdots, 0)$$

이다.

마찬가지 방법으로 **행렬  $A$ 의 왼쪽 특이벡터가 행렬  $AA^T$ 의 고유벡터가 된다는 것**을 증명할 수 있다.

```
w, V = np.linalg.eig(A.T @ A)

w  # A.T A의 고유값

array([12., 10.])

S ** 2  # A의 특잇값의 제곱

array([12., 10.])

V  # A.T A의 고유벡터

array([[ 0.70710678, -0.70710678],
       [ 0.70710678,  0.70710678]])

VT.T  # A의 오른쪽 특이벡터

array([[-0.70710678,  0.70710678],
       [-0.70710678, -0.70710678]])
```

## 연습 문제 3.4.3

NumPy를 사용하여 행렬  $A$ 의 왼쪽 특이벡터가 행렬  $AA^T$ 의 고유벡터가 된다는 것을 보여라.

$$A = \begin{bmatrix} 3 & -1 \\ 1 & 3 \\ 1 & 1 \end{bmatrix}$$


# 1차원 근사

2차원 평면 위에 3개의 2차원 벡터  $a_1, a_2, a_3$ 가 있다. 원점을 지나면서 모든 점들과 가능한 한 가까이 있는 직선을 만들고 싶다면 직선의 방향을 어떻게 해야 할까? 직선의 방향을 나타내는 단위 벡터를  $w$ 라고 하자.

```
w = np.array([2, 1]) / np.sqrt(5)
a1 = np.array([3, -1])
a2 = np.array([1, 3])
a3 = np.array([1, 1])

black = {"facecolor": "black"}

plt.figure(figsize=(9, 6))
plt.plot(0, 0, 'kP', ms=10)
plt.annotate(' ', xy=w, xytext=(0, 0), arrowprops=black)
plt.plot([-2, 8], [-1, 4], 'b--', lw=2)
plt.plot([a1[0], 2], [a1[1], 1], 'g:', lw=2)
plt.plot([a2[0], 2], [a2[1], 1], 'g:', lw=2)
plt.plot([a3[0], 1.2], [a3[1], 0.6], 'g:', lw=2)
plt.plot(a1[0], a1[1], 'ro', ms=10)
plt.plot(a2[0], a2[1], 'ro', ms=10)
plt.plot(a3[0], a3[1], 'ro', ms=10)
plt.text(0.1, 0.5, "$w$")
plt.text(a1[0] + 0.2, a1[1] + 0.2, "$a_1$")
plt.text(a2[0] + 0.2, a2[1] + 0.2, "$a_2$")
plt.text(a3[0] - 0.3, a3[1] + 0.2, "$a_3$")
plt.xticks(np.arange(-3, 15))
plt.yticks(np.arange(-1, 5))
plt.xlim(-3, 6)
plt.ylim(-2, 4)
plt.show()
```



벡터  $w$ 와 점  $a_i$ 의 거리의 제곱은 다음처럼 계산할 수 있다.(연습 문제 3.1.9)

$$\| a_i^\perp w \|^2 = \| a_i \|^2 - \| a_i^\parallel w \|^2 = \| a_i \|^2 - (a_i^T w)^2$$

벡터  $a_1, a_2, a_3$ 를 행벡터로 가지는 행렬  $A$ 를 가정하면

$$A = \begin{bmatrix} a_1^T \\ a_2^T \\ a_3^T \end{bmatrix}$$

행벡터의 놈의 제곱의 합은 행렬의 놈이므로 모든 점들과의 거리의 제곱의 합은 행렬의 놈으로 계산된다. (연습 문제 2.3.2)

$$\begin{aligned} \sum_{i=1}^3 \| a_i^\perp w \|^2 &= \sum_{i=1}^3 \| a_i \|^2 - \sum_{i=1}^3 (a_i^T w)^2 \\ &= \| A \|^2 - \| Aw \|^2 \end{aligned}$$

점  $a_i$ 의 위치가 고정되어 있으므로 행렬  $A$ 의 놈 값은 고정되어 있다. 따라서 이 값이 가장 작아지려면  $\| Aw \|^2$ 의 값이 가장 크게 만드는  $w$ 를 찾아야 한다.이 문제는 다음처럼 수식으로 쓸 수 있다.

$$\arg \max_w \|Aw\|^2$$

## 1차원 근사의 풀이

위에서 예로 든 행렬  $A \in \mathbf{R}^{3 \times 2}$ 를 특이분해하면 2개의 특잇값, 왼쪽/오른쪽 특이벡터를 가진다. 이를 각각 다음처럼 이름붙인다.

- 첫 번째 특잇값:  $\sigma_1$ , 첫 번째 왼쪽 특이벡터  $u_1 \in \mathbf{R}^3$ , 첫 번째 오른쪽 특이벡터  $v_1 \in \mathbf{R}^2$
- 두 번째 특잇값:  $\sigma_2$ , 두 번째 왼쪽 특이벡터  $u_2 \in \mathbf{R}^3$ , 두 번째 오른쪽 특이벡터  $v_2 \in \mathbf{R}^2$

첫 번째 특잇값  $\sigma_1$ 은 두 번째 특잇값  $\sigma_2$ 보다 같거나 크다.

$$\sigma_1 \geq \sigma_2$$

또한 위에서 알아낸 것처럼 A에 오른쪽 특이벡터를 곱하면 왼쪽 특이벡터 방향이 된다.

$$Av_1 = \sigma_1 u_1$$

$$Av_2 = \sigma_2 u_2$$

오른쪽 특이벡터  $v_1, v_2$ 는 서로 직교하므로 (같은 방향이 아니라서) 선형독립이고 2차원 평면공간의 기저벡터가 될 수 있다.

우리는  $\|Aw\|$ 의 값이 가장 크게 만드는  $w$ 를 찾아야 하는데  $w$ 는 2차원 벡터이므로 2차원 평면공간의 기저벡터인  $v_1, v_2$ 의 선형조합으로 표현할 수 있다.

$$w = w_1 v_1 + w_2 v_2$$

단,  $w$ 도 단위벡터이므로  $w_1, w_2$ 는 다음 조건을 만족해야 한다.

$$w_1^2 + w_2^2 = 1$$

이때  $\|Aw\|$ 의 값은

$$\begin{aligned} \|Aw\|^2 &= \|A(w_1 v_1 + w_2 v_2)\|^2 \\ &= \|w_1 Av_1 + w_2 Av_2\|^2 \\ &= \|w_1 \sigma_1 u_1 + w_2 \sigma_2 u_2\|^2 \\ &= \|w_1 \sigma_1 u_1\|^2 + \|w_2 \sigma_2 u_2\|^2 \text{ (orthogonal)} \\ &= w_1^2 \sigma_1^2 \|u_1\|^2 + w_2^2 \sigma_2^2 \|u_2\|^2 \\ &= w_1^2 \sigma_1^2 + w_2^2 \sigma_2^2 \text{ (unit vector)} \end{aligned}$$

$\sigma_1 > \sigma_2 > 0$  이므로  $w_1^2 + w_2^2 = 1$ 라는 조건을 만족하면서 위 값을 가장 크게 하는  $w_1, w_2$ 값은

$$w_1 = 1, w_2 = 0$$

이다. 즉, 첫 번째 오른쪽 특이벡터 방향으로 하는 것이다.

$$w = v_1$$

이때  $\|Aw\|$ 는 첫 번째 특잇값이 된다.

$$\|Aw\| = \|Av_1\| = \|\sigma_1 u_1\| = \sigma_1 \|u_1\| = \sigma_1$$

위에서 예로 들었던 행렬

$$A = \begin{bmatrix} 3 & -1 \\ 1 & 3 \\ 1 & 1 \end{bmatrix}$$

첫 번째 오른쪽 특이벡터



$$v_1 = \begin{bmatrix} \frac{\sqrt{2}}{2} \\ \frac{\sqrt{2}}{2} \end{bmatrix}$$

가 가장 거리의 합이 작은 방향이 된다. 그리고 이때의 거리의 제곱의 합은 다음과 같다.

$$\|A\|^2 - \|Aw\|^2 = \|A\|^2 - \sigma_1^2$$


```
np.linalg.norm(A)**2 - S[0]**2
```

```
9.999999999999998
```

```
w = np.array([1, 1]) / np.sqrt(2)
a1 = np.array([3, -1])
a2 = np.array([1, 3])
a3 = np.array([1, 1])

black = {"facecolor": "black"}

plt.figure(figsize=(9, 6))
plt.plot(0, 0, 'kP', ms=10)
plt.annotate('', xy=w, xytext=(0, 0), arrowprops=black)
plt.plot([-2, 4], [-2, 4], 'b--', lw=2)
plt.plot([a1[0], 1], [a1[1], 1], 'g:', lw=2)
plt.plot([a2[0], 2], [a2[1], 2], 'g:', lw=2)
plt.plot(a1[0], a1[1], 'ro', ms=10)
plt.plot(a2[0], a2[1], 'ro', ms=10)
plt.plot(a3[0], a3[1], 'ro', ms=10)
plt.text(0.1, 0.5, "$w$")
plt.text(a1[0] + 0.2, a1[1] + 0.2, "$a_1$")
plt.text(a2[0] + 0.2, a2[1] + 0.2, "$a_2$")
plt.text(a3[0] - 0.3, a3[1] + 0.2, "$a_3$")
plt.xticks(np.arange(-3, 15))
plt.yticks(np.arange(-1, 5))
plt.xlim(-3, 6)
plt.ylim(-2, 4)
plt.show()
```



## 일반적인 풀이

만약  $N = 3$ 이 아니라 일반적인 경우에는 다음처럼 풀 수 있다.

$$\begin{aligned}
\|Aw\|^2 &= \sum_{i=1}^N (a_i^T w)^2 \\
&= \sum_{i=1}^N (a_i^T w)^T (a_i^T w) \\
&= \sum_{i=1}^N w^T a_i a_i^T w \\
&= w^T \left( \sum_{i=1}^N a_i a_i^T \right) w \\
&= w^T A^T A w
\end{aligned}$$

분산행렬의 고유분해 공식을 이용하면,

$$\begin{aligned}
w^T A^T A w &= w^T V \Lambda V^T w \\
&= w^T \left( \sum_{i=1}^M \sigma_i^2 v_i v_i^T \right) w \\
&= \sum_{i=1}^M \sigma_i^2 (w^T v_i) (v_i^T w) \\
&= \sum_{i=1}^M \sigma_i^2 \|v_i^T w\|^2
\end{aligned}$$

이 된다. 이 식에서  $M$ 은 0이 아닌 특잇값 개수다.

즉, 우리가 풀어야 할 문제는 다음과 같다.

$$\arg \max_w \|Aw\|^2 = \arg \max_w \sum_{i=1}^M \sigma_i^2 \|v_i^T w\|^2$$

이 값을 가장 크게 하려면  $w$ 를 가장 큰 특잇값에 대응하는 오른쪽 고유벡터  $v_1$ 으로 해야 한다.

## 랭크-1 근사문제

또  $a_i$ 를  $w$ 에 투영한 벡터는

$$a_i^{\parallel w} = (a_i^T w) w$$

이므로  $w$  벡터를 이용하면  $N$ 개의  $M$ 차원 벡터  $a_1, a_2, \dots, a_N (a_i \in \mathbf{R}^M)$ 를 1차원으로 투영(projection)하여 가장 비슷한  $N$ 개의 1차원 벡터  $a_1^{\parallel w}, a_2^{\parallel w}, \dots, a_N^{\parallel w} (a_i^{\parallel w} \in \mathbf{R}^1)$ 를 만들 수 있다.

$$A' = \begin{bmatrix} (a_1^{\parallel w})^T \\ (a_2^{\parallel w})^T \\ \vdots \\ (a_N^{\parallel w})^T \end{bmatrix} = \begin{bmatrix} a_1^T w w^T \\ a_2^T w w^T \\ \vdots \\ a_N^T w w^T \end{bmatrix} = \begin{bmatrix} a_1^T \\ a_2^T \\ \vdots \\ a_N^T \end{bmatrix} w w^T = A w w^T$$

이 답은 원래 행렬  $A$ 에 랭크-1 행렬  $ww^T$ 를 곱해서 원래의 행렬  $A$ 와 가장 비슷한 행렬  $A'$ 을 만드는 문제와 같다.

$$\arg \min_w \|A - A'\| = \arg \min_w \|A - A w w^T\|$$

따라서 문제를 \*\*랭크-1 근사문제(rank-1 approximation problem)\*\*라고도 한다.

## K차원 근사

이번에는  $N$ 개의  $M$ 차원 벡터  $a_1, a_2, \dots, a_N (a_i \in \mathbf{R}^M)$ 를 1차원이 아니라 정규직교인 기저벡터  $w_1, w_2, \dots, w_K$ 로 이루어진  $K$ 차원 벡터공간으로 투영하여 가장 비슷한  $N$ 개의  $K$ 차원 벡터  $a_1^{\parallel w}, a_2^{\parallel w}, \dots, a_N^{\parallel w}$ 를 만들기 위한 정규직교 기저벡터  $w_1, w_2, \dots, w_K$ 를 찾는 문제를 생각하자. 이 문제는 랭크- $K$  근사문제라고 한다.

기저벡터행렬을  $W$ 라고 하자.

$$W = \begin{bmatrix} w_1 & w_2 & \cdots & w_K \end{bmatrix}$$

정규직교 기저벡터에 대한 벡터  $a_i$ 의 투영  $a_i^{\parallel w}$ 는 각 기저벡터에 대한 내적으로 만들 수 있다.

$$a_i^{\parallel w} = (a_i^T w_1)w_1 + (a_i^T w_2)w_2 + \cdots + (a_i^T w_K)w_K = \sum_{k=1}^K (a_i^T w_k)w_k$$

벡터  $a_1, a_2, \cdots, a_N$ 를 행벡터로 가지는 행렬  $A$ 를 가정하면

$$A = \begin{bmatrix} a_1^T \\ a_2^T \\ \vdots \\ a_N^T \end{bmatrix}$$

모든 점들과의 거리의 제곱의 합은 다음처럼 행렬의 norm으로 계산할 수 있다.

$$\begin{aligned} \sum_{i=1}^N \|a_i^\perp\|^2 &= \sum_{i=1}^N \|a_i\|^2 - \sum_{i=1}^N \|a_i^\parallel\|^2 \\ &= \|A\|^2 - \sum_{i=1}^N \|a_i^\parallel\|^2 \end{aligned}$$

행렬  $A$ 는 이미 주어져있으므로 이 값을 가장 작게 하려면 두 번째 항의 값을 가장 크게 하면 된다. 두 번째 항은  $K=1$ 일 때와 같은 방법으로 분산행렬 형태로 바꿀 수 있다.

$$\begin{aligned} \sum_{i=1}^N \|a_i^\parallel\|^2 &= \sum_{i=1}^N \sum_{k=1}^K \|(a_i^T w_k)w_k\|^2 \\ &= \sum_{i=1}^N \sum_{k=1}^K \|a_i^T w_k\|^2 \\ &= \sum_{k=1}^K w_k^T A^T A w_k \end{aligned}$$

분산행렬의 고유분해를 사용하면

$$\begin{aligned} \sum_{k=1}^K w_k^T A^T A w_k &= \sum_{k=1}^K w_k^T V \Lambda V^T w_k \\ &= \sum_{k=1}^K w_k^T \left( \sum_{i=1}^M \sigma_i^2 v_i v_i^T \right) w_k \\ &= \sum_{k=1}^K \sum_{i=1}^M \sigma_i^2 \|v_i^T w_k\|^2 \end{aligned}$$

이 문제도 1차원 근사문제처럼 풀면 다음과 같은 답을 얻을 수 있다.

가장 큰  $K$ 개의 특잇값에 대응하는 오른쪽 특이벡터가 기저벡터일 때 가장 값이 커진다.

## 랭크-K 근사문제

우리가 찾아야 하는 것은 이 값을 가장 크게 하는  $K$ 개의 영벡터가 아닌 직교하는 단위벡터  $w_k$ 이다. 고유분해의 성질로부터 **오른쪽 기저벡터 중 가장 큰  $K$ 개의 특잇값에 대응하는 오른쪽 특이벡터가 우리가 찾는 기저벡터가 된다.**

이 문제는 다음처럼 랭크- $K$  근사문제의 형태로 만들 수도 있다.

$$\begin{aligned}
 a_i^{\parallel w} &= (a_i^T w_1)w_1 + (a_i^T w_2)w_2 + \cdots + (a_i^T w_K)w_K \\
 &= \begin{bmatrix} w_1 & w_2 & \cdots & w_K \end{bmatrix} \begin{bmatrix} a_i^T w_1 \\ a_i^T w_2 \\ \vdots \\ a_i^T w_K \end{bmatrix} \\
 &= \begin{bmatrix} w_1 & w_2 & \cdots & w_K \end{bmatrix} \begin{bmatrix} w_1^T \\ w_2^T \\ \vdots \\ w_K^T \end{bmatrix} a_i \\
 &= WW^T a_i
 \end{aligned}$$

이러한 투영벡터를 모아놓은 행렬  $A'$ 는

$$A' = \begin{bmatrix} \left(a_1^{\parallel w}\right)^T \\ \left(a_2^{\parallel w}\right)^T \\ \vdots \\ \left(a_N^{\parallel w}\right)^T \end{bmatrix} = \begin{bmatrix} a_1^T WW^T \\ a_2^T WW^T \\ \vdots \\ a_N^T WW^T \end{bmatrix} = \begin{bmatrix} a_1^T \\ a_2^T \\ \vdots \\ a_N^T \end{bmatrix} WW^T = AWW^T$$


따라서 이 문제는 원래 행렬  $A$ 에 랭크-K 행렬  $WW^T$ 를 곱해서 원래의 행렬  $A$ 와 가장 비슷한 행렬  $A'$ 을 만드는 문제와 같다.

$$\arg \min_{w_1, \cdots, w_K} \| A - AWW^T \|$$

0 Comments - powered by utteranc.es

WritePreview

Sign in to comment

 Styling with Markdown is supported

Sign in with GitHub